

마지막 모수를 포함하여 하는 관찰값은 X_1, \dots, X_n 의 합을 통제량이라고 한다.

또 θ 의 체인 예비를 추정하기 위하여 사용하는 통제량 $T(X) = T(X_1, \dots, X_n)$ 을 θ 의 추정량이라고 한다.

$X_1 = d_1, X_2 = d_2, \dots, X_n = d_n$ 을 대체하여 구한 추정량의 특장값, $T(d) = T(d_1, \dots, d_n)$ 을 추정값이라고 한다.

E 4.1

$$\hat{\mu} = T_1(X_1, \dots, X_n) = \frac{\sum_i^n X_i}{n}, \quad \sigma^2 = T_2(X_1, \dots, X_n) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1} \text{은 추정량으로 사용할 수 있다.}$$

$$\text{이때, 표본 추정량 } \hat{\mu} \text{은 } T_1(d_1, \dots, d_n) = \frac{\sum_i^n d_i}{n}, \quad T_2(d_1, \dots, d_n) = \frac{\sum_{i=1}^n (d_i - \bar{d}_n)^2}{n-1} \text{은 추정값} \text{이다.}$$

4.1. 적률추정법.

모집단과 표본집단의 차이를 줄이는 방식으로 모수를 추정한다.

$$t\text{-계 모집단}(t\text{-th population moment}) : M_t = E(X^t)$$

$$t\text{-계 표본모수}(t\text{-th sample moment}) : m_t = \frac{\sum_i^n X_i^t}{n} \text{ 이고}$$

M'_t 은 모집단 $\theta = (d_1, \dots, d_k)$ 의 합으로 k 개의 연립방정식을 풀면 $\hat{d}_1, \dots, \hat{d}_k$ 을 찾을 수 있다.

즉, 모수의 계수에 적률방정식을 넣고 표본모수와 모집단을 일치시키는 행렬식을 풀면 모집단을 추정한다.

E 4.2

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ Random sample. μ, σ^2 를 적률방정법을 사용하여 추정하라.

$$M'_1 = E(X) \quad m'_1 = \frac{\sum_i^n X_i}{n} = \bar{X} \quad \left. \right| \text{연립방정식 사용.}$$

$$M'_2 = E(X^2) \quad m'_2 = \frac{\sum_i^n X_i^2}{n} = \sigma^2 + \mu^2$$

$$\hat{\mu} = \frac{\sum_i^n X_i}{n}, \quad \hat{\sigma}^2 = m'_2 - (m'_1)^2 = \frac{\sum_i^n X_i^2}{n} - \left(\frac{\sum_i^n X_i}{n} \right)^2 = \frac{1}{n} \left(\sum_i^n X_i^2 - n(\bar{X})^2 \right) = \frac{\sum_i^n (X_i - \bar{X})^2}{n}$$

E.4.3

$X_1, \dots, X_n \sim \text{Geom}(k, \theta)$ Random Sample.

$$\begin{aligned} m'_1 &= \frac{\sum_{i=1}^n X_i}{n} = M'_1(k, \theta) = k\theta \\ m'_2 &= \frac{\sum_{i=1}^n X_i^2}{n} = M'_2(k, \theta) = k\theta^2 + k^2\theta^2 \end{aligned} \quad \left. \right\} \text{연립방정식}$$

$$\bar{X} = k\theta, \quad k\theta^2 = m'_2 - (m'_1)^2 = \sum_{i=1}^n \frac{X_i^2}{n} - \left(\sum_{i=1}^n \frac{X_i}{n}\right)^2 = \sum_{i=1}^n \frac{X_i^2}{n} - (\bar{X})^2 = \frac{1}{n} \left(\sum_{i=1}^n X_i^2 - n(\bar{X})^2 \right) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

$$J = \frac{\bar{X}}{k} \text{ 이므로 } k^2 \times \frac{\bar{X}^2}{k^2} = \frac{\bar{X}^2}{k^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} \Rightarrow k = \frac{n(\bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$J = \frac{\bar{X}}{\frac{n(\bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}} = \frac{\bar{X} \cdot \sum_{i=1}^n (X_i - \bar{X})^2}{n(\bar{X})^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n\bar{X}}$$

4.2 최대가능도 추정법

설명: $p(0.1 \text{ or } 0.9)$ 인 배터리 충전기에 대해 초기 100번 충전회수를 했을 때, 60회는 0.9로 예측된다.

가능도함수는 $L(\theta)$ 로 쓰고 $f(x_1, \dots, x_n; \theta)$ 이다. 즉 x_1, \dots, x_n 을 할 때, 모두 0을 찾을 것이다.

여기 예에서 찾는 θ 이고 x_1, \dots, x_n 은 0이 해당하는 것이다.

가능도함수는 $\hat{\theta}(\theta)$ 의 형태로 학습할 것이다.

가능도함수는 특정한 시점에서 모수를 추정하기에 편리한 모양을 측정할 수 있다.

→ 그래서 모수를 찾기 빨라서 $n \rightarrow \infty$ 이면 추정하는 방향(즉, 모수)이 정해진다.

이를 일관성(Consistency)이라고 한다.

$L(\theta; x_1, \dots, x_n)$ 은 최대가능도 $\hat{\theta}$ 의 값을 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 이라고 할 때,

$\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 은 $\hat{\theta}$ 의 최대가능도 추정량이라고 한다.

'실제로 관측된' 자료가 얻어낸 학점을 가장 크게 만드는 (즉, 주어진 조건들을 가장 잘 설명하는)

$\hat{\theta}$ 값을 $\hat{\theta}$ 의 추정량으로 삼는 것이다.

$$L(\theta; d_1, \dots, d_n) = \prod_{i=1}^n f(d_i; \theta)$$

개인의 편의를 위하여 성을 불러 사용한다. 성은 단조 증가함수이므로 불러도 상관없다.

E.4.5

$X_1, \dots, X_n \sim EXP(\lambda)$ Random Sample.

$$L(\lambda; d_1, \dots, d_n) = \prod_{i=1}^n f(d_i; \lambda) = \prod_{i=1}^n \frac{1}{\lambda} e^{-\frac{d_i}{\lambda}} = \frac{1}{\lambda^n} e^{-\frac{\sum d_i}{\lambda}}$$

$$\lambda L(\lambda) = -\frac{\sum d_i}{\lambda} - n \ln \lambda \quad \frac{\partial \lambda L(\lambda)}{\partial \lambda} = -\frac{n}{\lambda} + \frac{\sum d_i}{\lambda^2} \Rightarrow \frac{n}{\lambda} = \frac{\sum d_i}{\lambda^2} \quad \hat{\lambda} = \frac{\sum d_i}{n} = \bar{d}$$

$\hat{\lambda} = \bar{d}$ 일 때, 아래에 있는 예와 같은으로 이 결과가 가능성을 확보된다.

E.4.6

$X_1, \dots, X_n \sim poi(\lambda)$ Random Sample.

$$L(\lambda; d_1, \dots, d_n) = \prod_{i=1}^n \frac{\lambda^{d_i} \lambda^{-\lambda}}{d_i!} \cdot \frac{\lambda^{\sum d_i} e^{-\lambda}}{\lambda^{\sum d_i}} \quad \lambda L(\lambda) = \sum d_i / \lambda - n \lambda - \ln(\lambda^{\sum d_i})$$

$$\lambda L(\lambda) = \frac{\sum d_i}{\lambda} - n = 0 \Rightarrow \hat{\lambda} = \frac{\sum d_i}{n} = \bar{d}$$

이제 $\lambda = \bar{d}$ 이 확률(확률) 확대이다.

E.4.7

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$

$$L(\mu, \sigma^2; d_1, \dots, d_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(d_i-\mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \cdot e^{-\frac{\sum (d_i-\mu)^2}{2\sigma^2}} = \left(\frac{n}{2\pi\sigma^2}\right)^{\frac{n}{2}} \cdot e^{-\frac{\sum (d_i-\mu)^2}{2\sigma^2}}$$

$$\lambda(\mu, \sigma^2) = \frac{n}{2} \cdot \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{\sum (d_i-\mu)^2}{2\sigma^2} = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum (d_i-\mu)^2}{2\sigma^2}$$

$$\frac{\partial \lambda(\mu, \sigma^2)}{\partial \mu} = \frac{\partial \sum (d_i-\mu)^2}{\partial \mu} = \frac{\sum 2(d_i-\mu)}{\sigma^2} = 0 \Rightarrow \sum_{i=1}^n d_i = n\mu \quad \mu = \frac{\sum d_i}{n} = \bar{d}$$

$$\frac{\partial \lambda(\mu, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{\partial \ln}{\partial \sigma^2} + \frac{2\sum (d_i-\mu)^2}{4\sigma^4} = -\frac{n}{2\sigma^2} + \frac{\sum (d_i-\mu)^2}{2\sigma^4} = 0$$

$$\Rightarrow \sigma^2 = \frac{\sum (d_i-\bar{d})^2}{n}$$

$$\therefore \hat{\mu} = \bar{d} \quad \hat{\sigma}^2 = \frac{\sum (d_i-\bar{d})^2}{n}$$

E. 4.8

$$X_1, \dots, X_n \sim \text{Logistic} \quad f(\theta; \beta) = \frac{e^{-(\beta-\theta)}}{(1+e^{-(\beta-\theta)})^2}, \quad -\infty < \beta < \infty, \quad -\infty < \theta < \infty \text{ 이다.}$$

$$\ell(\theta) = \sum_{i=1}^n \ln \left(\frac{e^{-(\beta-\theta)}}{(1+e^{-(\beta-\theta)})^2} \right) = \sum_{i=1}^n (-\beta + \theta - \ln(1+e^{-\beta+\theta})) = -\sum_{i=1}^n \beta + n\theta - 2\sum_{i=1}^n \ln(1+e^{-\beta+\theta})$$

$$\ell'(\theta) = n - 2\sum_{i=1}^n \frac{e^{-\beta+\theta}}{1+e^{-\beta+\theta}} = 0 \quad \text{간단한 해는 존재하지 않나 } \quad \text{단조증가함수이고 } \quad \theta \rightarrow -\infty \text{ 일 때, } n, \ell(\theta) \text{ 늘어 } \rightarrow -\infty$$

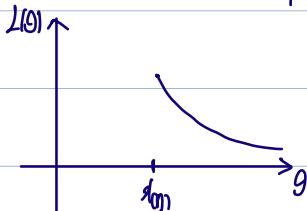
증명법 \Rightarrow 증명법 \Rightarrow 증명법 \Rightarrow 증명법.

· 가능한 경우는 단지나 미분 가능한 것은 아니다. 단지 최대값도 확정되어 정상 미분방정을 풀어서 구하는 것은 어렵다.

E. 4.9

$$X_1, \dots, X_n \sim U(0, \theta)$$

$$L(\theta; d_1, \dots, d_n) = \prod_{i=1}^n f(d_i; \theta) = \begin{cases} \theta^n & 0 < d_i \leq \theta \\ 0 & \text{otherwise} \end{cases} \quad) \text{ 확률이 불가능한 경우이다.}$$



d_1, \dots, d_n 중에 하나라도 $d_i > \theta$ 를 만족하면 어려

d_1, \dots, d_n 중에 가장 큰 값은 d_m 이 되면 가능하다.

$d_m \in \mathbb{N}$ 인 경우 $L(\theta)$ 의 정의에 의해 $L(\theta)$ 가 정해진다.

E. 4.10

$$X_1, \dots, X_n \sim \text{PDI}(\lambda)$$

$$\ell(\lambda) = \sum_{i=1}^n \ln \left(\frac{\lambda^i e^{-\lambda}}{i!} \right) = \sum_{i=1}^n (\ln(\lambda) - \lambda - \ln(i!)) = \lambda n - \sum_{i=1}^n \ln(i!) - n\lambda$$

$$\ell'(\lambda) = \frac{\sum_{i=1}^n i}{\lambda} - n = 0 \Rightarrow \lambda = \frac{\sum_{i=1}^n i}{n} = \bar{x}_n \quad \bar{x}_n = 0 \text{라면 } \ell(\lambda) \text{ 가 항상 } \infty \text{ 를 가진다.}$$

그리고 $\lambda = 0$ 이 아닐 때에는 가능한 경우 $\lambda = \bar{x}_n$ 일 때는 최대값을 확정하는 존재성이 있다.

E.4.11

$X_1, \dots, X_n \sim U(0-1, 0+1)$ Random Sample.

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n I(0-1 \leq x_i \leq 0+1) = f(x)^n I(0-1 \leq x_{(1)}, x_{(n)} \leq 0+1) = 2^{-n} I(x_{(1)}-1 \leq \theta \leq x_{(n)}+1)$$

구간 $x_{(1)}-1, x_{(n)}+1$ 의 모든 점에서 최대값을 찾는다.

즉 구간내 모든 점이 최대가능도 추정량이 된다.

E.4.12

$$(N_1, N_2, N_3) \sim \text{MULT}(n, p_1, p_2, p_3)$$

$$p_1 = \theta^2, p_2 = 2\theta(1-\theta), p_3 = (1-\theta)^2 \quad 0 < \theta < 1 \text{ 일 때, } \theta \text{의 최대가능도 추정량은?}$$

$$N_1 = n_1, N_2 = n_2, N_3 = n_3$$

$$L(\theta) = \frac{n!}{n_1! n_2! n_3!} \theta^{2n_1} (2\theta(1-\theta))^{n_2} (1-\theta)^{2n_3}$$

$$l(\theta) = \ln\left(\frac{n!}{n_1! n_2! n_3!}\right) + 2n_1 \ln \theta + n_2 \ln(2\theta(1-\theta)) + 2n_3 \ln(1-\theta)$$

$$l'(\theta) = \frac{2n_1}{\theta} + \frac{n_2}{1-\theta} - \frac{n_2}{1-\theta} - \frac{2n_3}{1-\theta} = 0 \text{ 이므로 } \theta \text{의 최대가능도 추정량은 } \hat{\theta} = \frac{n_1 + n_2}{2n}$$

$$2n_1(1-\theta) + n_2(1-\theta) - \theta n_2 - 2\theta n_3 = 2n_1 - 2n_1\theta + n_2 - \theta n_2 - \theta n_2 - 2\theta n_3 = 2n_1 + n_2 - 2n_1\theta - 2n_2\theta - 2n_3\theta$$

$$= 2n_1 + n_2 - 2\theta(n_1 + n_2 + n_3) = 0 \quad \theta = \frac{2n_1 + n_2}{2(n_1 + n_2 + n_3)} = \frac{2n_1 + n_2}{2n} \quad (n_1 + n_2 + n_3 = n)$$

최대가능도 추정량은 $\hat{\theta} = \frac{2n_1 + n_2}{2n}$

$$\begin{array}{ll} n_1 = n_1 & n_3 = n_3 \\ \hat{\theta} = 0 & \hat{\theta} = 1 \end{array}$$

· 최대가능도 추정량의 불변성

$T(X)$ 을 추정하는 어떤 추정량이 $T(X)$ 일 때, $T(X)$ 의 추정량은 $T(X)^2$ 가 되고 $T(X) + C$ 는 $T(X) + C$ 이다.

즉 $T(X)$ 의 추정량이 $T(T(X))$ 가 되는 성질을 불변성 원칙 (invariance property)라고 한다.

여기서 $T(X)$ 은 $T(X)$ 을 찾고 다른 형태의 보조를 끊게 만들 수 있다.

<증명>

$$\eta = g(\theta) \quad L^*(g(\theta)) = L^*(\eta) = \prod_{i=1}^n f(x_i; g^{-1}(\eta)) = L(g^{-1}(\eta)) = L(\theta) \text{ 이고}$$

$$\max_{\eta \in g(\Omega)} L^*(\eta) = \max_{\eta \in g(\Omega)} L(g^{-1}(\eta)) = \max_{\theta \in g(\Omega)} L(\theta) \text{ 이므로}$$

$$L^*(\hat{\eta}) = \max_{\eta \in g(\Omega)} L^*(\eta) = \max_{\theta \in g(\Omega)} L(\theta) = L(\hat{\theta}) = L^*(g(\hat{\theta})) \text{ 이다.}$$

$$\therefore \hat{\eta} = g(\hat{\theta}) \text{ 이다.}$$

E. 4.13

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \text{ 입가} \quad g(\theta) = \sigma = \text{최대가능도 추정량은 불변성이 있어 } \hat{\theta} = \hat{\sigma}^2 \rightarrow \text{된다.}$$

E. 4.14

$x_1, \dots, x_n \sim \text{Exp}(\lambda)$ Random Sample.

$$l(\lambda) = \sum_{i=1}^n \ln(\lambda e^{-\lambda}) = \sum_{i=1}^n \left(\ln \lambda - \frac{\lambda}{\lambda} \right) = -n \ln \lambda - \sum_{i=1}^n \frac{\lambda}{\lambda}$$

$$l'(\lambda) = -\frac{n}{\lambda} + \frac{\sum_{i=1}^n \lambda}{\lambda^2} = 0 \quad \frac{n}{\lambda} = \frac{\sum_{i=1}^n \lambda}{\lambda^2} \quad \lambda = \frac{\sum_{i=1}^n \lambda}{n} = \bar{x}_n \text{ 이므로 } \hat{\lambda} = \bar{x}_n$$

$$\text{만약 확률변수가 보다 큰 확률에 관심이 있다면 } g(\lambda) = P(X \geq 1) = \int_1^\infty \frac{1}{\lambda} e^{-\lambda} d\lambda = [-e^{-\lambda}]_1^\infty = e^{-\lambda}$$

$$\text{이므로 } g(\hat{\lambda}) = e^{-\bar{x}_n} \text{ 이 된다.}$$

4.3 추정의 기준.

학습보조를 살피는 것은 추정량의 성격을 파악하는데 도움을 줄다.

E. 4.15

$x_1, \dots, x_n \sim U(0, 1)$ Random Sample.

f(x) 최대가능도 추정량은 $X_{(1)}$ 이다. $X_{(1)}$ 의 확률은 $\theta = 1, n=5$ 인 경우

$$1. \quad f(X_{(1)}) = n \cdot [F(x_{(1)})]^{n-1} \cdot f(x_{(1)}) = 5 \cdot \left[\frac{x_{(1)}}{\theta} \right]^4 \cdot \frac{1}{\theta} = \frac{5}{\theta^5} x_{(1)}^4 \quad (0 < x_{(1)} < 1)$$

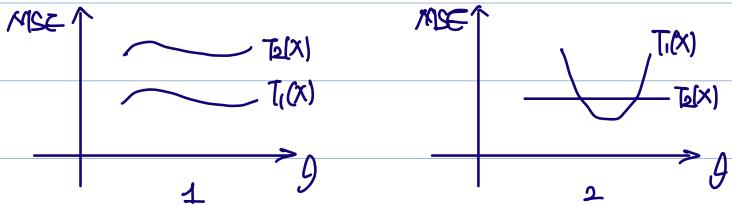
$$2. \quad F_{X_{(1)}}(x) = P(X_{(1)} \leq x) = P(X_1 \leq x, \dots, X_5 \leq x) = \underbrace{\underbrace{P(X \leq x)}_1}_{1}^5 = (F_X(x))^5 = x^5 \quad (0 < x < 1)$$

$$f_{T_1(X)}(\theta) = \text{스텟}(0 < \theta < 1)$$

↳ 표본최대값이 기보의 적연 확률 분포도 모두 같다,
모든 관측값이 기보의 적연 확률 분포 확률도 기보인 것이다.

Loss function : $(T(X) - g(\theta))^2$ 이고 Loss function 또한 학습방법으로 이를 최소화하는
추정량 $T(X)$ 을 찾는 것은 불가능하다. 그래서 손실함수의 개선형을 찾으려고 한다.

즉 $MSE = E(T(X) - g(\theta))^2$ 를 사용한다.



1번 경우는 $T_1(X)$ 은 정상 $\mu(\theta)$ 보다 훨씬 작은 이기며 어떤 추정량($T(X)$)을 사용할 때
평균값의 차이. 이렇게 차이를 그린 $f(\theta)$ 로써 미지수 θ 에 대한 최대화하는 것은 문제 X.

관측적인 추정량을 제작하기 위한 비판적 추정량을 계획하라

$T(X)$ 을 $\mu(\theta)$ 의 추정량이라고 할 때, $E(T(X)) - \mu(\theta)$ 를 관찰하고 하고

$E(T(X)) - \mu(\theta) = 0$ 이면 $T(X)$ 은 $\mu(\theta)$ 의 비판적 추정량이다.

E.4.17

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ Random Sample.

$T_1(X) = \bar{X}_n$ $T_2(X) = \frac{X_1 + X_2}{2}$ 는 $E(T_1(X)) = E(T_2(X)) = \mu$ 이므로 모두 모정한 μ 의 비판적 추정량이다.

E.4.18

$\mathcal{U}(0,1)$ 에서 고려한 최대값은 추정량 $X_{(n)}$ 은 확률을 줄 수 있다. 즉 개선하는 모형은 확률이다.

$$\text{증명해보면 } E(X_{(n)}) = \int_0^n k \cdot \frac{n}{\binom{n}{k}} \cdot k!(n-k)! - \int_0^n n \cdot \frac{\binom{n}{k}}{\binom{n}{k}} dk = \frac{n}{n+1} \cdot \frac{1}{\binom{n+1}{0}} \left[k(n+1) \right]_0^n = \frac{n}{n+1} \cdot \frac{\binom{n+1}{1}}{\binom{n+1}{0}} = \frac{n}{n+1} \theta$$

$\frac{n}{n+1}$ 은 θ 보다 작다. 즉, 비판적 추정량이다.

$$T_1(x) = \frac{n+1}{n} \cdot x_{(1)} \in E(T_1(x)) = \frac{n+1}{n} \cdot \frac{1}{n+1} \cdot 0 = 0 \text{ 이며 } T_1(x) \text{ 는 비전향적 추정량이다.}$$

$g(\theta)$ 의 추정량 $T(x)$ 의 MSE는 $MSE = \text{Var}(T(x)) + (\text{bias})^2 \cdot id.$

<증명>

$$\begin{aligned} MSE &= (T(x) - g(\theta))^2 = E(T(x) - E(T(x)) + E(T(x)) - g(\theta))^2 \\ &= E((T(x) - E(T(x)))^2) + E(E(T(x)) - g(\theta))^2 + 2E((T(x) - E(T(x)))(E(T(x)) - g(\theta))) \\ &= \text{Var}(T(x)) + (E(T(x)) - g(\theta))^2 + 2E((T(x) - E(T(x))) \{ E(T(x)) - g(\theta) \}) \\ &= \text{Var}(T(x)) + (\text{Bias})^2 \end{aligned}$$

비전향 추정량 중에서 더 좋은 것을 뜻하고 이를 빙수(Variance Ratio)를 이용해.

$T_1(x), T_2(x)$ 가 비전향 추정량일 때, $\frac{\text{Var}(T_2(x))}{\text{Var}(T_1(x))}$ 를 $T_1(x)$ 의 $T_2(x)$ 에 대한 상대효율이라고 한다.

E. 4.19

$$E. 4.17 \text{ 에서 } T_1(x) = \bar{x}_{(1)} \text{ 과 } T_2(x) = \frac{x_1 + x_2}{2} \text{은 } \text{적은 } \text{Var}(T_1(x)) = \frac{\sigma^2}{n} \text{, } \text{Var}(T_2(x)) = \frac{\sigma^2}{2}$$

$$\frac{\text{Var}(T_2(x))}{\text{Var}(T_1(x))} = \frac{\frac{\sigma^2}{2}}{\frac{\sigma^2}{n}} = \frac{1}{2} \text{이므로 } \text{Var}(T_2(x)) \text{가 } \text{Var}(T_1(x)) \text{보다 } \text{효율} \text{인 } \text{추정량이다.}$$

E. 4.20

$$U(0, \theta) \text{의 } \theta \text{에 대한 비전향 추정량은 } \hat{\theta} = T_1(x) = \frac{n+1}{n} x_{(1)} \cdot id. \quad X_{(1)} = \frac{n}{n+1} T_1(x)$$

$$f_{T_1}(t) = f_{X_{(1)}}\left(\frac{n}{n+1}t\right) \left| \frac{d}{dt} \left(\frac{n}{n+1}t\right) \right| = n \cdot \left(\frac{n}{n+1}t\right)^{n-1} \cdot \frac{1}{n} \cdot \frac{n}{n+1} = \frac{n}{\theta^n} \cdot \left(\frac{n}{n+1}\right)^n \cdot t^{n-1} \quad I(0 \leq t \leq \frac{n+1}{n}\theta)$$

이제 $X_{(1)}$ 의 비전향 추정량으로 구해보자.

$$f_{X_{(1)}}(x_{(1)}) = n \cdot \left(1 - \frac{x_{(1)}}{\theta}\right)^{n-1} \cdot \frac{1}{\theta} = \frac{n}{\theta} \left(1 - \frac{x_{(1)}}{\theta}\right)^{n-1}, \quad 0 < x < \theta$$

$$E(X_{(1)}) = \int_0^\theta x \cdot \frac{n}{\theta} \cdot \left(1 - \frac{x}{\theta}\right)^{n-1} dx = \frac{n}{\theta} \int_0^\theta x \left(1 - \frac{x}{\theta}\right)^{n-1} dx = \frac{n}{\theta} \cdot \frac{\theta^n}{n(n+1)} = \frac{\theta}{n+1}$$

즉, 비편향추정량으로 $T_1(x) = (n+1)X_{(1)}$ 을 생각할 수 있다.

$\text{Var}(T_1(x))$, $\text{Var}(T_2(x))$ 는 ?) 가 하여 $E(T_1(x)^2)$, $E(T_2(x)^2)$ 를 구하라.

$$\begin{aligned} E(T_1^2) &= \int_0^{n+1} t^2 \cdot \frac{n}{t^n} \cdot \left(\frac{n}{n+1}\right)^n \cdot t^{n-1} dt = \frac{n}{D^n} \cdot \left(\frac{n}{n+1}\right)^n \int_0^{n+1} t^{n+1} dt = \frac{n}{D^n} \cdot \left(\frac{n}{n+1}\right)^n \cdot \frac{(n+1)^2}{n+2} \cdot D^{n+2} \theta^2 \\ &= \frac{(n+1)^2}{n} \cdot \frac{\theta^2}{n+2} = \frac{(n+1)^2}{n(n+2)} \theta^2 \end{aligned}$$

$$\text{Var}(T_1(x)) = \frac{(n+1)^2}{n(n+2)} \theta^2 - \theta^2 = \frac{\theta^2}{n(n+2)} \quad \text{id.}$$

$$f_{T_2}(t) = f_{X_{(1)}}\left(\frac{t}{n+1}\right) \mid \frac{dt/t}{d(t/n+1)} = n \cdot \left(1 - \frac{t}{n+1}\right)^{n-1} \cdot \frac{1}{n+1} = n \left(\frac{n+1-t}{n+1}\right)^{n-1} \cdot \frac{1}{n+1} = \frac{n}{n+1} \cdot \frac{1}{n+1} \cdot (1 - \frac{t}{n+1})^{n-1} \quad \text{if } 0 \leq t \leq (n+1)\theta$$

$$\begin{aligned} E(T_2^2) &= \int_0^{(n+1)\theta} t^2 \cdot \frac{1}{D^n} \cdot \frac{n}{n+1} \cdot \left(1 - \frac{t}{n+1}\right)^{n-1} dt = \frac{n}{D^n(n+1)} \int_0^{(n+1)\theta} t^2 \cdot (1 - \frac{t}{n+1})^{n-1} dt \\ &= \left(\frac{1}{D(n+1)}\right)^n \cdot n \int_0^{(n+1)\theta} t^2 (n+1-\theta-t)^{n-1} dt = \frac{1}{D^n(n+1)^n} \cdot n \cdot \frac{2}{n(n+1)(n+2)} \cdot \frac{(n+2)^2 \theta^2}{(n+1)^{n+2}} = \frac{(n+1)^2 \cdot 2n \theta^2}{n(n+1)(n+2)} = \frac{2(n+1)\theta^2}{n+2} \end{aligned}$$

$$E(T_2) = \theta^2$$

$$\text{Var}(T_2) = \frac{2(n+1)\theta^2}{n+2} - \theta^2 = \left(\frac{n+2}{n+2} - \frac{n+2}{n+2}\right) \theta^2 = \frac{n}{n+2} \theta^2$$

$$\frac{\text{Var}(T_1(x))}{\text{Var}(T_2(x))} = \frac{\frac{1}{n(n+2)} \theta^2}{\frac{n}{n+2} \theta^2} = \frac{n+1}{n^2(n+2)} = \frac{1}{n^2} \quad n > 1 \text{ 일 때, } T_2 \text{는 } T_1 \text{의 비례 확장이 됨.}$$

여기서 T_2 는 T_1 과 같은 분포를 갖기 위해 표본의 크기를 n^2 배로 가져야 한다.

하지만 비편향추정량은 고지보류 확률이 0이 되는 경우 표본의 가장 좋은 추정량을 찾을까?

이는 표본의 100% 비편향추정량 즉, 표본의 비편향추정량을 찾고 한다.

4.4 최소불란 비편향 추정량 (Minimum Variance Unbiased Estimator, MVUE)

비편향 추정량 중에서 최소불란을 가지는 추정량을 선택하는 것이다.

1. $T^*(x)$ 는 θ (0)의 비편향추정량이다.

2. θ (0)의 임의의 비편향추정량 $T(x)$ 에 대하여 $\text{Var}(T^*(x)) \leq \text{Var}(T(x))$ 를 만족한다.

어떻게 MVUE를 구하나?

1. 그레비-리온 정리 : 불란 추정량은 고지보류 비편향 추정량이 가능할 수 있는 특성의 핵심입니다.

2. 라이 블랙홀의 정의, 러빈 케리의 정의 by 앤비뉴튼定律

1. 그레미-라이

그레미-라이의 정보부등식은 비편향추정량이 가질 수 있는 불순의 하한을 제시한다.

이 하한을 그레미-라이 하한값이라고 한다.

어떤 비편향추정량도 이보다 작은 불순은 가질 수 없다.

즉 어떤 비편향추정량이 이 값을 가진다면 그는 최적이다.

정보부등식이 사용되는 파악의 정보 $I(Y)$ 는 $I(Y) = E\left[\left(\frac{\partial}{\partial Y} \log f(Y; \theta)\right)^2\right]$ 으로 정의된다.

E. 4.21

$$X \sim N(\mu, \sigma^2) \text{ 일 때, } f(x; \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$I(\mu) = E\left[\left(\frac{\partial}{\partial \mu} \log f(X; \mu)\right)^2\right] = E\left[\left(\frac{X-\mu}{\sigma^2}\right)^2\right] = E\left[\frac{1}{\sigma^4} \cdot (X-\mu)^2\right] = \frac{1}{\sigma^4} E[(X-\mu)^2] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}$$

이가 가질 수 있는 편향은 X 가 오른쪽 μ 에 대해서 가리는 정보의 양은 적어진다.

그리고 $I(\mu)$ 는 μ 의 값에 비례하여 증가한다.

$X \sim N(\mu, \sigma^2)$ $Y \sim N(\mu, \sigma^2)$ 에서 $\mu < \sigma^2$ 일 때 X 를 쓰는게 좋다.

E. 4.22

생산률이 p 인 배터리 블로.

$$f_X(x; p) = p^x (1-p)^{1-x} \quad (x=0,1, 0 < p < 1) \quad \log f_X(x; p) = X \log p + (1-X) \log (1-p)$$

$$\frac{\partial}{\partial p} \log f_X(x; p) = \frac{X}{p} - \frac{1-X}{1-p} = \frac{X-p}{p(1-p)}$$

$$E\left[\left(\frac{\partial}{\partial p} \log f_X(x; p)\right)^2\right] = E\left[\left(\frac{X-p}{p(1-p)}\right)^2\right] = \frac{E((X-p)^2)}{p^2(1-p)^2} = \frac{E(X^2) - 2pE(X) + E(p^2)}{p^2(1-p)^2} = \frac{p(1-p)}{p^2(1-p)^2} = \frac{1}{p(1-p)}$$

$p = \frac{1}{2}$ 일 때, 파악의 정보가 가장 적다.

· 정보부등식 (Information Inequality)

(1) 오류가 다르면 pdf가 달라.

(2) $A = \{x : f(x; \theta) > 0\}$ 는 모든 θ 에 의존하지 않으며, 모든 $x \in A$, $\theta \in \Omega$ 에 대해서

$f(x; \theta)$ 는 θ 에 대해서 두 번 미분가능하고, 그导数가 한정적이다.

(3) $T(X)$ 가 모든 $\theta \in \Omega$ 에 대해서 $E(T(X)) < \infty$ 라면

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} f(x_1; \theta) dx_1 \cdots dx_n$$

$$= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n \text{이다.}$$

이제 모든 $\theta \in \Omega$ 에 대해서 $\text{Var}(T(X)) < \infty$, $E(T(X)) = g(\theta)$, $0 < I(\theta) < \infty$ 라고 하면

$g(\theta)$ 는 미분가능하여 $\text{Var}(T(X)) \geq \frac{(g'(\theta))^2}{nI(\theta)}$ 이 성립한다.

<증명>

$T(X)$ 는 $g(\theta)$ 의 비편향 추정량으로 $E(T(X)) = g(\theta)$ 이다.

$$(E(T(X)))' = g'(\theta) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} f(x_1; \theta) dx_1 \cdots dx_n$$

$$= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n - g(\theta) \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n$$

$$(\because \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n = 1 \text{ 이므로 } \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \dots, x_n) \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n = 0)$$

$$= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} [T(x_1, \dots, x_n) - g(\theta)] \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n$$

$$= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} [T(x_1, \dots, x_n) - g(\theta)] \left[\frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) \right] \times \frac{\partial^2}{\partial \theta^2} f(x_1; \theta) dx_1 \cdots dx_n$$

$$= E[(T(x_1, \dots, x_n) - g(\theta)) \cdot (\frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_1; \theta))] \text{ 이 성립한다.}$$

즉 $E(T(X))$ 에 대한 증명

증명을 끝내기

$$E(X^2) E(Y^2) \geq E(XY)^2$$

$$[g(\theta)]^2 \leq E[(T(X) - g(\theta))^2] \cdot E\left[\left(\frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_i; \theta)\right)^2\right] = \text{Var}(T(X)) \times E\left[\left(\frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_i; \theta)\right)^2\right]$$

$$\therefore \text{Var}(T(X)) = \frac{[g'(\theta)]^2}{E\left[\left(\frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_i; \theta)\right)^2\right]} \text{ 이 성립한다.}$$

$$\text{증명)} \quad E\left[\frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_i; \theta)\right] = \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} / \frac{\partial^2}{\partial \theta^2} f(x_i; \theta) f(x_i; \theta) dx_i = \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} f(x_i; \theta) dx_i = \frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(x_i; \theta) dx_i$$

$$= \frac{\partial}{\partial \theta} \cdot 1 = 0 \text{ 이다.}$$

$$E[(\frac{\partial}{\partial \theta} \log f(x_i; \theta))^2] = E[(\frac{\partial^2}{\partial \theta^2} \log f(x_i; \theta))^2] = \sum_{i=1}^n \sum_{j=1}^n E[\frac{\partial^2}{\partial \theta_j^2} \log f(x_i; \theta)] E[\frac{\partial^2}{\partial \theta_j^2} \log f(x_i; \theta)]$$

$$= n E[(\frac{\partial}{\partial \theta} \log f(x_i; \theta))^2] \text{이다.}$$

(X_i 는 iid인 각각 다른 샘플을 이용한 것이다.)

즉, $T(X)$ 가 λ 의 비倚향적 추정량이 되고 한때면, $\text{Var}(T(X)) \geq \frac{1}{nI(\lambda)} \circ$ 가 성립된다.

E. 4.23

$X_1, \dots, X_n \sim \text{PVI}(\lambda)$ Random Sample.

$$I(\lambda) = E[(\frac{\partial}{\partial \lambda} \log f(x; \lambda))^2] = E[(\frac{X}{\lambda} - 1)^2] = E[(\frac{X-\lambda}{\lambda})^2] = \frac{1}{\lambda}$$

그러나 $\text{Var}(X_n) = \frac{1}{n} \circ$ 이고 $\frac{1}{nI(\lambda)} = \frac{\lambda}{n} \circ$ 이므로 X_n 은 최소불편 추정량이다.

E. 4.24

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ Random sample.

$$I(\mu) = E[(\frac{\partial}{\partial \mu} \log f(x; \mu))^2] = \frac{1}{\sigma^2} \circ \text{and} \quad \frac{1}{nI(\mu)} = \frac{\sigma^2}{n} \circ \text{and} \quad \bar{X}_n \text{은 MVUE이다.}$$

즉 하위집합을 선택해도 MVUE는 아니다. 하위집합에 대해서도 MVUE가 될 수 있다.

. 완전통계량, (MVUE를 구하는 방법)

충분통계량

$S(X) = (S_1(X), \dots, S_l(X))$ 를 l 개 통계량의 벡터라고 하자.

이제, 조건부 충분한수 $(X_1, \dots, X_n) | S(X)$ 의 분포가 모수 $\theta = (\theta_1, \dots, \theta_k)$ 에 의존하지 않으면

$S(X)$ 를 결합충분통계량(jointly sufficient statistic)이라고 한다.

不完備통계량 ($l=1$)의 경우는 $S(X)$ 가 θ 의 충분통계량이라고 한다.

· 충분통계량에 대한 설명.

충분통계량의 값이 일정하면 표본의 결합분포는 더 이상 모수에 의존하지 않는다.

즉 표본은 모수가 고정된 어떤 정分布 가지고 있어야 한다는 의미이다.

표본이 모수추정에 사용되는 이는 확률변수 X_1, \dots, X_n 같은 모수의 확률가 예측인

그 블록이 모수가 의존하기 때문이다.

하지만 충분통계량의 값이 조건부로 일정하면 더 이상 블록이 모수에 의존하지 않도록

모수추정에 사용할 힘을 끌어내린다.

예를 들어 표본 X_1, \dots, X_n 이 고정되어 있을 때, 모수가 대량 정分布는 모두 충분통계량 $S(X)$

모수에 의하고 편 드 한다.

그리고 자료의 측도가 가능하다. 모수 추정이 목적이라면 충분통계량을 가지고 있어도

같은 효과를 가지는 추정값을 얻을 수 있다.

E. 4.25

$$X_1, \dots, X_n \sim \text{Ber}(p) \quad S = \sum_{i=1}^n X_i$$

$$f_S(s; p) = \binom{n}{s} p^s (1-p)^{n-s} \quad (s=0, 1, \dots, n) \quad S = \sum_{i=1}^n X_i \text{ } \sim \text{Bin}(n, p) \text{에 대한 충분통계량.}$$

$$f(d_1, \dots, d_n | S) = p(X_1=d_1, \dots, X_n=d_n | S=s) = \frac{P(X_1=d_1, \dots, X_n=d_n, S=s)}{P(S=s)} = \begin{cases} \frac{P(X_1=d_1, \dots, X_n=d_n, S=s)}{P(S=s)}, & S = \sum_{i=1}^n d_i \\ 0 & \text{otherwise} \end{cases}$$

$$f(d_1, \dots, d_n | S) = \frac{f(d_1, \dots, d_n | S)}{f(S)} = \frac{p^{S(1-p)^{n-S}}}{\binom{n}{S} p^S (1-p)^{n-S}} = \frac{1}{\binom{n}{S}}, \quad S = \sum_{i=1}^n d_i$$

d_1, \dots, d_n 은 모두 일정이 흔히에 따른 정수이 수는 서로다른다.

이는 모수 p 에 의존하지 않으므로 $S = \sum_{i=1}^n X_i$ 는 p 에 충분통계량이다.

· (S_1, \dots, S_m) 이 결합충분통계량이면 (S_1, \dots, S_m) 의 $1/1$ 험도 역시 결합충분통계량이다.

Bkt! 통계량이 충분한치를 갖을 때, 복합한 조건부 pdf를 구하는 과정이 필요해짐

대신 인수분해 정리 (factorization theorem)을 이용하면 보다 간단히 헤아릴 수 있다.

또한 어떤 통계량이 충분통계량일지 결정할 때 필요로 하는 조건은 다음과 같다.

인수분해 정리.

$x_1, \dots, x_n \sim \text{joint pdf } f(x_1, \dots, x_n; \theta)$ 일 때, $s(x) = (s_1(x), \dots, s_k(x))$ 를 k 개의 통계량

이며 s 가 결합통계량일 필요충분조건은 $\text{joint pdf } f(x_1, \dots, x_n; \theta)$ 은 s 에 대한 $g(s)$, (x_1, \dots, x_n) 에 대한 $h(x)$

곱으로 나타내어지는 것이다.

$$f(x_1, \dots, x_n; \theta) = g(s(x); \theta) \times h(x_1, \dots, x_n)$$

<증명>

s 가 결합통계량이고, s 의 pdf를 $f_s(s; \theta)$ 로 표기하면

$$f(x_1, \dots, x_n; \theta) = \frac{f_s(s; \theta)}{f_{X|S}(x_1, \dots, x_n | s)} f_{X|S}(x_1, \dots, x_n | s) = g(s; \theta) h(x_1, \dots, x_n)$$

$\hookrightarrow s$ 를 일련의 표상에 의존하지 않는다.

E. 4.26

$X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ Random Sample.

$$f(x_1, \dots, x_n; p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} I_{\{x_i=0,1\}} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \prod_{i=1}^n I_{\{x_i=0,1\}}$$

$$s = \sum_{i=1}^n x_i \text{ 일 때, } h(x_1, \dots, x_n) = \prod_{i=1}^n I_{\{x_i=0,1\}}(x_i) = \begin{cases} 1 & \text{if } x_i = 0, 1 \quad i = 1, \dots, n \\ 0 & \text{otherwise} \end{cases}$$

$$g(s; p) = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} = p^s (1-p)^{n-s}$$

$f(x_1, \dots, x_n; p) = g(s; p) h(x_1, \dots, x_n)$ 의 증명은 표현 가능하다. 그래서 $\sum_{i=1}^n x_i$ 는 충분통계량이다.

E. 4.27

$X_1, \dots, X_n \sim U(\theta_1, \theta_2)$ Random Sample.

$$f(x_1, \dots, x_n; \theta_1, \theta_2) = \prod_{i=1}^n \frac{1}{\theta_2 - \theta_1} I(\theta_1 < x_i < \theta_2) = \left(\frac{1}{\theta_2 - \theta_1}\right)^n \prod_{i=1}^n I(\theta_1 < x_i < \theta_2)$$

$$= \left(\frac{1}{\theta_2 - \theta_1}\right)^n I(\theta_1 < x_{(1)} \text{ and } x_{(n)} < \theta_2)$$

E. 4.28

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ Random Sample.

$$f(x_1, \dots, x_n; \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - 2\mu x_i + \mu^2)} \cdot 1.$$

$$f(x_1, \dots, x_n; \mu, \sigma^2) = g(S(x); \mu, \sigma^2) \cdot h(x_1, \dots, x_n) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - 2\mu x_i + \mu^2)} \times 1 \cdot 1.$$

또한 2개 이므로 $S = \sum_{i=1}^n x_i$, $S^2 = \sum_{i=1}^n x_i^2$ 가 결합통계량이다. 그리고 S , $\sum_{i=1}^n (X_i - \bar{X})^2$ 도 결합통계량이다.

E. 4.29

$X_1, \dots, X_n \sim f(x; \theta)$ Random Sample.

결합통계량은 결합통계량이다. 주어진 $x_{(1)}, \dots, x_{(n)}$ 이 대하여 $(X_1, \dots, X_n) = 1$ 가 될 수 있는 모든 $n!$ 가지이다.

그리고 $\frac{n!}{S!}$ 는 $\frac{1}{n!}$ 이므로 모든 θ 에 의존하지 않는다.

결합통계량은 유일하지 않다. 그렇다면 어떤 결합통계량을 사용?

▶ 모든 정수를 얻기 위해서 차례로 숫자를 뽑아야 하는 것!

즉 모든 자연수는 정수를 가장 적게 가지고 있는 것을 원함!

▶ 그런 것을 최소 결합통계량이라고 한다.

S 가 1 의 결합통계량일 때,

S 가 1 의 결합통계량일 때 S 가 최소 결합통계량이 되고

S 를 얻면 S 를 놓기 때문에 나는 S 보다 더 큰 정수를 가진다.

크론 - 불리Kelly 정리 : 결합통계량을 빨리 얻는 확장방법의 원리

즉 x 의 확률 $p(x)$ 가 대해서 $T(x)$ 가 결합통계량이고, $T(X)$ 가 그의 한 비결합통계량이라고 하면.

이때, $S(S) = E(T(X)|S)$ 라고 하면 $S(S)$ 도 역시 $p(x)$ 의 비결합통계량이며,

모든 θ 에 대해서 $V\theta(S(S)) = E[(S(S) - p(x))^2] \leq E[(T(X) - p(x))^2] = V\theta(T(X))$ 가 성립한다.

<증명>

$\{S_i\}$ 는 모든 i 에 따른 X_i , $E(S(S)) = E(T(X)) = \mu$ 으로 비전방향성이다.

(정의. 2/3) $\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}(E(Y|X))$ 이므로 $Y = T(X)$, $X = S$ 라고 하면

$$\text{Var}(T(X)) = E(\text{Var}(T(X)|S)) + \text{Var}(E(T(X)|S))$$

$$\hookrightarrow E[(T(X) - E(T(X)|S))^2|S] = E[(T(X) - S(S))^2|S]$$

$$= E[E(T(X) - S(S))^2|S] + \text{Var}(S(S)) \geq \text{Var}(S(S))$$

위의 내용은 $U.E(T(X))$ 가 충족하면 충분통계량 S 에 대한 조건부 가중치 $E(T(X)|S)$ 역시 UE 이며,

$T(X)$ 보다 적거나 같은 불일치를 가진다.

따라서 MLE를 찾을 때, 그 확률을 충분통계량의 확률로 주는 시킬 수 있다.

E. 4.30

$X_1, \dots, X_n \sim \text{Bern}(p)$ Random Sample.

X_i 는 모든 i 에 UE 이다. ($E(X_i) = p$) 그리고 충분통계량 $S = \sum_{i=1}^n X_i$ 가 주어졌을 때,

X 의 조건부 확률분포를 살펴보니 아래와 같은 불일치를 갖는 UE 를 찾았습니다.

X_i 는 1 또는 0을 가지기의 확률변수.

$$P(X_i=0 | \sum_{i=1}^n X_i = s) = \frac{P(X_i=0, \sum_{i=1}^n X_i = s)}{P(\sum_{i=1}^n X_i = s)} = \frac{P(X_i=0) P(\sum_{i=1}^n X_i = s)}{P(\sum_{i=1}^n X_i = s)}$$

$$= \frac{\binom{n}{s} p^s (1-p)^{n-s}}{\binom{n}{s} p^s (1-p)^{n-s}} = \frac{\frac{(n-1)!}{(n-s)!} s! (n-s)!}{\frac{n!}{(n-s)! s!}} = \frac{n-s}{n}$$

$$P(X_i=1 | \sum_{i=1}^n X_i = s) = \frac{P(X_i=1, \sum_{i=1}^n X_i = s)}{P(\sum_{i=1}^n X_i = s)} = \frac{P(X_i=1, \sum_{i=2}^n X_i = s-1)}{P(\sum_{i=1}^n X_i = s)} = \frac{P(X_i=1) P(\sum_{i=2}^n X_i = s-1)}{P(\sum_{i=1}^n X_i = s)}$$

$$= \frac{\frac{1}{s} \cdot \binom{n-1}{s-1} p^{s-1} (1-p)^{n-s}}{\binom{n}{s} p^s (1-p)^{n-s}} = \frac{\binom{n-1}{s-1}}{\binom{n}{s}} = \frac{\frac{(n-1)!}{(n-s)! (s-1)!}}{\frac{n!}{(n-s)! s!}} = \frac{(n-s)! s! (n-1)!}{n! (n-s)! (s-1)!} = \frac{s}{n}$$

$$E(X_i | \sum_{i=1}^n X_i = s) = 0 \times \frac{n-s}{n} + 1 \times \frac{s}{n} = \frac{s}{n}$$

즉 $\frac{S}{n}$ 은 p 의 시보드 U.P.가 된다. (e-블록체인 정의에 따르면 $\frac{S}{n} \leq p/hp$ 이다.)

실제로 $\frac{\sum_i X_i}{n}$ 이 시보드 $\frac{p/hp}{n}$ 이다.

충분통계량의 충분성이 비례상 충분성이 가질한 정의 그것이 유일한 MLE가 된다는 것을 알 수 있다.

여기서 충분통계량 S가 있어서 이 충분통계량의 충분성이 U.P. S*(S)로 가질한다고 하면,

즉 $S^*(S)$ 보다 더 좋은 U.P.가 있는 충분성이 있다면 어떤 U.P. T(X)를 가능하야.

만약 $T(X)$ 가 S의 충분성이 아니면 $E(T(X)|S)$ 가 더 좋은 U.P.가 될 것이고 이것이 가장 좋은 유한정답률에

$E(T(X)|S) = S^*(S)$ 가 될 것이다.

그리고 $T(X)$ 가 S의 충분성이 그 자체가 $S^*(S)$ 와 같은 두 가지가 있다.

이 유일성(uniqueness)을 다른데 있어 중요한 도구가 되는 완비성(completeness)이 대체로 필요하다.

Random Sample X_1, \dots, X_n 으로서 가능한 통계량 $S=S(X_1, \dots, X_n)$ 이 대체로

$E(g(S))=0$ 을 모든 $g \in G$ 에 대해 만족하는 데에 충분한 충분성이 $g(\cdot)=0$ 만족하는

S를 완비통계량이라고 한다. 만약 S가 S에 대한 충분통계량이라면, 이를 완비충분통계량이라고 한다.

不完비통계량은 통계량에 대한 충분성이 모든 확률에 대해 0이 될 때, 그 확률이 항상 0인 경우밖에 0이 될 때,
→ 확률이 상관없이 항상 0일 때,

不完비성의 다른 설명.

不完비성은 추정량을 찾을 때, 불가능한 정보를 제공하는 거 같다.

어떤 통계량 S(X)가 완비통계량이라는 것은

"어떤 확률 g(S)가 대개 0이 되려면, 그 확률이 항상 0일 수밖에 없다"는 뜻이다.

즉, 불가능한 정보는 포함하지 않는 통계량이라는 것이다.

어떤 충분통계량 $S(X)$ 가 원시통계량이라면, 아래의 봉투법을 쓰면 $g(S)$ 를 만들수 있다.

$E[g(T)] = 0$ 일 때, 0이 될 수 있는 경우가 $g(t) > 0$ 되는 경우수가 없다면 원시값을 만들수 있다.

E.4.31

$X_1, \dots, X_n \sim \text{Ber}(p)$ Random Sample.

예를 들어 $X_1 - X_2$ 는 원시통계량이 아님. $E[X_1 - X_2] = 0$ 이지만 $X_1 - X_2$ 는 항상 0이 되기 때문이다.

$T = \sum_{i=1}^n X_i$ 가 원시통계량인지 살펴보자.

$$T \sim \text{Bin}(n, p) \text{ 이므로 } E[g(T)] = \sum_{t=0}^n g(t) \binom{n}{t} p^t (1-p)^{n-t} = (1-p)^n \sum_{t=0}^n g(t) \binom{n}{t} \left(\frac{p}{1-p}\right)^t = 0 \text{ 이 되면 } \binom{n}{t} \left(\frac{p}{1-p}\right)^t, (1-p)^n \in 0 < p < 1 \text{ 이므로 절대 } 0 \text{이 될 수 없으므로 } g(t) > 0 \text{ 이 되어야 한다.}$$

즉 $g(t) = 0$ 이다.

E.4.32

$X_1, \dots, X_n \sim U(0, \theta)$ Random Sample.

$$f_{X(n)}(y) = n \cdot F(y)^{n-1} f(y) = n \cdot \left(\frac{y}{\theta}\right)^{n-1} \frac{1}{\theta}, \quad 0 < y < \theta \text{이다.}$$

$$E[g(X(n))] = \int_0^\theta g(y) \cdot \frac{n y^{n-1}}{\theta^n} dy = \frac{n}{\theta^n} \int_0^\theta g(y) y^{n-1} dy \text{에서 } E[g(X(n))] = 0 \text{ 이라는 것은}$$

$\int_0^\theta g(y) y^{n-1} dy$ 가 0이어야 한다. 이 식을 0에 미분하면 $g(0) \theta^{n-1} = 0$ 이 모든 $\theta > 0$ 에 대하여 성립함을 의미하고

θ^{n-1} 은 0이 될 수 없으므로 $g(0)$ 가 0이 되어야 한다.

즉 $X(n)$ 은 원시값을 만들수 있고 충분통계량이므로 원시통계량이다.

마지막 - 회고록.

모든 0이 대하여 T 가 원시통계량이고, $T(X)$ 가 $g(0)$ 의 배전량통계량이라고 하자.

$S(S) = E(T(X)|S)$ 는 $g(0)$ 의 유일한 고유한 비간접 추정량 (MVUE)이다.

최소 불확실 정리에 따르니 기존의 불편향증량보다 더 작은 불편향증량을 찾을 수 있으면 그게 더 좋다.
 최소불확실을 찾는 것은 아니다. 하지만 충분통계량이 추정치로 인해 더 낮아지면 비편향증량은 커질 것이다
 최소불확실을 정리에 따라 계산한 MVUE가 된다.

E. 4.33

$X_1, \dots, X_n \sim U(0, \theta)$ Random Sample.

$X_{(n)}$ 이 원비율불확량 같은 특성을 갖다. 그리고 $E\left(\frac{n+1}{n}X_{(n)}\right) = \theta$ 이므로 $\frac{(n+1)X_{(n)}}{n}$ 은 유일한 MVUE이다.

이번 같이 원비율불확량은 철학적이어 매우 유용한 역할을 한다. 그래서 높은 계산을 필요로 한다.
 그러나 그들이 증명되는 자주들은 원비율불확량 보장되고, 자주 사용되는 많은 확률분포가 자주하기 드러스트로 이를 쉽게 활용할 수 있다.

제1종 확률밀도함수: 친수 $a, b, c_i, t_i, (i=1, \dots, k)$ 에 대하여

$$f(x; \theta) = a(\theta) b(\theta) e^{\sum_{i=1}^k c_i(\theta) t_i(x)}, -\infty < x < \infty$$

$\theta = \theta_1, \dots, \theta_k$ 로 표현되면 이를 매개 변수 $\theta_1, \dots, \theta_k$ 를 가진 자주하기 드러스트로 이를 표기하고 한다.

여기서 $d: f(x; \theta) > 0$ 은 꼭 예제에 맞는다.

E. 4.34

$$f(x; p) = p^x (1-p)^{1-x} = (1-p) e^{x \ln(1-p)} \geq \text{표현되므로 } a(p) = 1-p, b(p) = 1, c(p) = \ln(1-p), t(x) = x = L.$$

$\exists x: f(x; p) > 0 \Rightarrow x \in \{0, 1\}$ 즉 모수가 0이나 1인 자주하기 드러스트로 가능하다.

따라서 베르누이 확률은 모수가 0이나 1인 자주하기 드러운다.

$$f(x; \lambda) = \frac{e^{-\lambda} \cdot \lambda^x}{x!}, x = 0, 1, 2, \dots = e^{-\lambda} \cdot \frac{1}{x!} e^{x \ln \lambda} \geq \text{표현 가능.}$$

$$a(\lambda) = e^{-\lambda}, b(\lambda) = \frac{1}{\lambda!}, c(\lambda) = \ln \lambda, t(x) = x \geq \text{자주하기 드러운다.}$$

의미: $f_{X_i}(\lambda) > 0 \iff \lambda = 0, 1, 2, \dots$ 일 때 X_i 의 분포.

$$f_{X_i}(\lambda) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\lambda-\mu)^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}} e^{-\frac{\lambda^2 - 2\mu\lambda + \mu^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}} e^{-\frac{\lambda^2}{2\sigma^2} + \frac{\mu^2}{\sigma^2} - \frac{2\mu\lambda}{\sigma^2}}$$

$$\lambda(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{\mu^2}{2\sigma^2}}, b(\lambda) = 1, c(\mu, \sigma^2) = e^{-\frac{\mu^2}{2\sigma^2}}, d(\mu, \sigma^2) = \frac{\mu}{\sigma^2}, t(\lambda) = \lambda^2, u(\lambda) = \lambda \text{ 일 때 } f_{X_i}(\lambda) = \lambda^2 e^{-\frac{\lambda^2}{2\sigma^2}}.$$

여기에서 $\lambda(\mu, \sigma^2) > 0$ 일 때 확률변수 X_i 의 분포가 정의된다.

이제 X_i 가 주어진 확률변수들인 각별로, 배수별로, 합수별로, 합성분수들에 대해

그러면 $S_i = \sum_{j=1}^k a_j X_j$ ($a_1, \dots, a_k > 0$ 일 때 S_i 가 정의되는 조건은 각각의 정의에 따르면 정의된다).

정의 4.7

X_i 가 주어진 확률변수 $f_{X_i}(x_i) = a_i(x_i) b_i(x_i) e^{-\sum_{j=1}^k c_j(x_i) d_j(x_i)}$ 일 때 X_1, \dots, X_n 을 한 번에

통계량 $S_i = \sum_{j=1}^n a_j(X_j)$, $\dots, S_k = \sum_{j=1}^n a_k(X_j)$ 은 모든 i_1, \dots, i_k 에 대한 결합확률분포를 갖는다.

S_1, \dots, S_k 의 확률을 구하는 i_1, \dots, i_k 의 비전향적합량은 i_1, \dots, i_k 의 MVE이다.

(연습문제 1: 1 확률로 유비통계량이 된다.)

E. 4.35

$X_1, \dots, X_n \sim \text{Bern}(p)$ Random Sample.

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n; p) = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i} \quad (x_i = 0, 1, 0 < p < 1)$$

이면 $S = \sum_{i=1}^n X_i$ 는 모든 p 에 대한 연습문제량의 확률 $p(S)$ 을 갖는다.

$\text{Var}(S) = p/(1-p)$ 의 MVE를 구하고자 한다. 이기 전에 확률 $p(1-p)$ 을 사용하면,

$$E(S(1-p)) = E(S) - E(S^2) = p - (p^2 + \text{Var}(S)) = p - p^2 - \frac{p(1-p)}{n} = p(1-p)(1 - \frac{1}{n}) \geq 0$$

$$S(1-p) \times \frac{1}{1-p} = S(1-p) \cdot \frac{n}{n-1} = \frac{n \cdot S(1-p)}{n-1} \text{은 연습문제량의 합수이며, 비전향적합량으로}$$

$\text{Var}(S) = \text{MVE}$ 이다.

E. 4.36

$X_1, \dots, X_n \sim \text{Poisson}$ Random Sample.

$$f(d_1, \dots, d_n; \lambda) = \prod_{i=1}^n \frac{\lambda^{d_i} e^{-\lambda}}{d_i!} = \frac{e^{-n\lambda} \lambda^{\sum d_i}}{\prod d_i!}, \quad (d_i = 0, 1, 2, \dots) \text{ 가 된다.}$$

$\sum d_i X_i$ 는 인비几率통계량이며 그의 1:1 함수 X_i 도 인비几率통계량이다.

이에 λ 를 추정할 때 X_i 를 사용하면 $E(X_i) = \lambda$ 이고 X_i 는 MVUE가 된다.

E. 4.37

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ Random Sample.

$$f(d_1, \dots, d_n; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(X_i - \mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{\sum (X_i - \mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{\sum d_i^2}{2\sigma^2} + n\frac{\sum d_i}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}} \rightarrow \text{Normality}$$

$\sum d_i^2, \sum d_i$ 은 4.34, 4.73에서 결론한 인비几率통계량이다.

이들의 합인 S_n 과 $\sum d_i (X_i - \bar{X}_n)^2 / n$ 은 각각 S_n 과 $\sum d_i$ 의 부전통추정량으로 이들 S_n 은 MVUE이다.

만약 μ 가 알려져 있다면 $\sum d_i (X_i - \mu)^2$ 는 인비几率통계량이며, $\sum d_i (X_i - \mu)^2 / n$ 은 μ 의 MVUE가 된다.

σ^2 의 최대가능도 추정량은 $\sum d_i (X_i - \bar{X}_n)^2 / n$ 의 σ^2 를 이산경우는 정의한 σ^2 를 모으면 값이 다르게 된다.

부전통의 (인비几率통계량의 상수를 곱하여서 표본의 정리를 살펴보기)

$S = (S_1, \dots, S_k)$ 가 모든 (J_1, \dots, J_k) 의 결합 인비几率통계량이라고 하자. 아래 어떤 통계량 T 를 볼까?

모든 $J = (J_1, \dots, J_k)$ 이 \neq 일 때 T 의 확률이다.

부전통도 할까? T 의 의존성이 없는 통계량 T 를 T 의 부전통통계량이라고 한다.

부전통의 정리를 적용하면, 두 통계량의 확률을 보는지 않아서 두 통계량의 부인한 결합으로 구하기 쉽도록 한다.

E. 4.38

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ Random Sample.

$$\hat{\sigma}^2 = \sum d_i (X_i - \bar{X}_n)^2 / n, \quad \hat{\mu} = \bar{X}_n \text{ 을 생각해보기.}$$

X_n 은 λ 의 인비几率통계량이고, $\frac{n \hat{\sigma}^2}{\hat{\mu}^2} \sim \chi^2_{(n-1)}$ 이므로 이는 λ 의 의존성이 있는다.

즉, $\frac{\partial L}{\partial \theta_j}$ 는 세기 대신 보정계수인 $\hat{\mu}_j$ 를, 비례계수인 $\hat{\sigma}^2 = \sum_i (X_i - \bar{X})^2 / n$ 은 수치이다.